

一种超低损失的深度神经网络量化压缩方法^{*}

龚 成^{1,2}, 卢 冶^{1,2}, 代素蓉^{1,2}, 刘方鑫^{1,2}, 陈新伟³, 李 涛^{1,2,4}

¹(南开大学 计算机学院, 天津 300350)

²(天津市网络和数据安全技术重点实验室(南开大学), 天津 300350)

³(工业机器人应用福建省高校工程研究中心(闽江学院), 福建 福州 350121)

⁴(计算机体系结构国家重点实验室(中国科学院 计算技术研究所), 北京 100190)

通讯作者: 卢冶, E-mail: luyel@nankai.edu.cn



摘 要: 深度神经网络(deep neural network, 简称 DNN)量化是一种高效的模型压缩方法, 使用少量位宽表示模型计算过程中的参数和中间结果数据。数据位宽会直接影响内存占用、计算效率和能耗。以往的模型量化研究缺乏有效的定量分析, 这导致量化损失难以预测。提出了一种超低损失的 DNN 量化方法(ultra-low loss quantization, 简称 μ L2Q), 以揭示量化位宽与量化损失之间的内在联系, 指导量化位宽选择并降低量化损失。首先, 将原始数据映射为标准正态分布的数据; 然后, 在等宽的量化区间中搜索最优量化参数; 最后, 将 μ L2Q 方法融合进 DNN 的训练过程, 并嵌入到主流的机器学习框架 Caffe 及 Keras 中, 以支撑端到端模型压缩的设计和训练。实验结果表明, 与最新的研究方法相比, 在相同的位宽条件下, μ L2Q 方法能够保证更高的模型精度, 在典型的神经网络模型上精度分别提高了 1.94%、3.73% 和 8.24%。显著性物体检测实验结果表明, μ L2Q 方法能够胜任复杂的计算机视觉任务。

关键词: 神经网络压缩; 神经网络量化; 权值分布; 均匀量化; 量化损失最优解

中图法分类号: TP181

中文引用格式: 龚成, 卢冶, 代素蓉, 刘方鑫, 陈新伟, 李涛. 一种超低损失的深度神经网络量化压缩方法. 软件学报, 2021, 32(8): 2391–2407. <http://www.jos.org.cn/1000-9825/6189.htm>

英文引用格式: Gong C, Lu Y, Dai SR, Liu FX, Chen XW, Li T. Ultra-low loss quantization method for deep neural network compression. Ruan Jian Xue Bao/Journal of Software, 2021, 32(8): 2391–2407 (in Chinese). <http://www.jos.org.cn/1000-9825/6189.htm>

Ultra-low Loss Quantization Method for Deep Neural Network Compression

GONG Cheng^{1,2}, LU Ye^{1,2}, DAI Su-Rong^{1,2}, LIU Fang-Xin^{1,2}, CHEN Xin-Wei³, LI Tao^{1,2,4}

¹(College of Computer Science, [Nankai University](#) Tianjin 300350, China)

²(Tianjin Key Laboratory of Network and Data Security Technology ([Nankai University](#)), Tianjin 300350, China)

³(Industrial Robot Application of Fujian University Engineering Research Center (Minjiang University), Fujian 350121, China)

* 基金项目: 国家重点研发计划(2018YFB2100300); 国家自然科学基金(62002175, 61872200); 天津自然科学基金(19JCZDJC31600, 19JCQNJC00600); 计算机体系结构国家重点实验室(中国科学院计算技术研究所)开放课题(CARCHB202016, CARCH201905); 中国高校产学研创新基金(2020HYA01003); 工业机器人应用福建省高校工程研究中心(闽江学院)开放基金(MJUKF-IRA1902)

Foundation item: National Key Research and Development Program of China (2018YFB2100300); National Natural Science Foundation of China (62002175, 61872200); Natural Science Foundation of Tianjin Municipality (19JCZDJC31600, 19JCQNJC00600); Open Fund of State Key Laboratory of Computer Architecture (Institute of Computing Technology, Chinese Academy of Sciences) (CARCHB202016, CARCH201905); Innovation Fund of Chinese Universities Industry-University-Research (2020HYA01003); Open Fund of Industrial Robot Application of Fujian University Engineering Research Center (Minjiang University) (MJUKF-IRA1902)

本文由“泛在嵌入式智能系统”专题特约编辑郭兵教授、王泉教授、邓庆绪教授、陈铭松教授、张凯龙副教授推荐。

收稿时间: 2020-07-21; 修改时间: 2020-09-07; 采用时间: 2020-11-02; jos 在线出版时间: 2021-02-07