

УДК 004.8

DOI: 10.18413/2518-1092-2025-10-4-0-6

Хрупин Д.С.,
Шапцев В.А.

МЕТОД КВАНТОВАНИЯ НЕЙРОННЫХ СЕТЕЙ
ОБНАРУЖЕНИЯ НА ВСТРАИВАЕМЫХ СИСТЕМАХ

Тюменский государственный университет,
ул. Володарского, 6, г. Тюмень, 625003, Россия

e-mail: Khrupin24@mail.ru, vashaptsev@ya.ru

Аннотация

Квантование моделей является ключевым методом развертывания высокопроизводительных нейросетевых детекторов объектов на устройствах с ограниченными ресурсами. Однако стандартные подходы к квантованию, такие как PTQ, QAT и даже методы смешанной точности, оптимизируют распределение числа битов по показателю чувствительности слоев, игнорируя семантическую специфику задачи. Это приводит к существенному снижению точности при различении семантически близких классов, что критично для многих практических приложений. В статье предложен новый подход к квантованию со смешанной точностью, который учитывает семантику задачи. Введена метрика семантической значимости компонентов сети, вносящих ключевой вклад в различение трудноразличимых классов. На её основе формируется гетерогенная конфигурация битности, которое обеспечивает высокую точность критически важных частей модели, допуская агрессивное сжатие остальных. Представлен план экспериментальной валидации подхода на задаче определения типа транспортного средства. Ожидается значительно лучший компромисс между точностью и ресурсоемкостью модифицированной нейросетевой модели по сравнению со стандартными техниками квантования.

Ключевые слова: квантование нейронных сетей; распознавание объектов; встраиваемые системы; глубокое обучение; сжатие моделей; адаптивная длина двоичных значений коэффициентов; смешанная точность; метрика семантической значимости

Для цитирования: Хрупин Д.С., Шапцев В.А. Метод квантования нейронных сетей обнаружения на встраиваемых системах // Научный результат. Информационные технологии. – Т.10, №4, 2025. – С. 70-76. DOI: 10.18413/2518-1092-2025-10-4-0-6

Khrupin D.S.
Shaptsev V.A.

QUANTIZATION METHOD FOR DETECTION NEURAL
NETWORKS ON EMBEDDED SYSTEMS

Tyumen State University, 6 Volodarsky St., Tyumen, 625003, Russia

e-mail: Khrupin24@mail.ru, vashaptsev@ya.ru

Abstract

Model quantization is a key method for deploying high-performance neural network object detectors on resource-constrained devices. However, standard quantization approaches, such as PTQ, QAT, and even mixed-precision methods, optimize the distribution of bits based on the sensitivity of layers, ignoring the semantic specificity of the task. This leads to a significant decrease in accuracy when distinguishing between semantically similar classes, which is critical for many practical applications. The article proposes a new approach to mixed-precision quantization that takes into account the semantics of the task. A metric of semantic significance of network components that make a key contribution to the discrimination of difficult-to-distinguish classes is introduced. Based on it, a heterogeneous bit configuration is formed, which ensures high accuracy of critically important parts of the model, allowing aggressive compression of the rest. A plan for experimental validation of the approach on the task of determining the type of vehicle is